

Résumé

Ce dossier de veille met l'accent sur les différentes familles de l'intelligence artificielle, principalement l'apprentissage profond et son rôle dans le succès d'autres branches de l'IA. Ce travail défend aussi la nécessité de comprendre l'IA dans son ensemble et toute sa complexité, et non de la réduire à un domaine particulier. Seule démarche possible si l'on veut avoir des systèmes plus robustes et mieux adaptés aux problèmes du monde réel.

Mots-clés : IA, apprentissage automatique, apprentissage profond, IA symbolique, agent

Abstract

This paper focuses on the different families of artificial intelligence, primarily deep learning and its role in the success of other AI branches. This work also emphasizes the necessity of understanding AI as a whole, in all its complexity, rather than reducing it to a particular domain. This is the only approach if we want to develop more robust systems that are better adapted to real-world problems.

Keywords: AI, machine learning, deep learning, symbolic AI, agent

Liste des figures

Figure 2-1 Les grands domaines de l'intelligence artificielle.....	9
Figure 2-3 Régression et classification.....	10
Figure 2-2 Les approches en apprentissage automatique.....	10
Figure 2-4 Représentation Random Forest.....	12
Figure 2-6 Régression vs Deep learning.....	18
Figure 2-7 RNN vs feedforward	19
Figure 2-8 Représentation CNN	20

Table des matières

Résumé	i
Abstract	i
Liste des figures	ii
Introduction	1
Intérêt de la recherche	2
Méthodologie	2
L'intelligence artificielle	3
1.1 Approches de l'intelligence artificielle	3
1.1.1 Agir comme un humain (" <i>Acting humanly</i> ").....	3
1.1.2 Penser comme un humain (" <i>Thinking humanly</i> ").....	4
1.1.3 Penser rationnellement (" <i>Thinking rationally</i> ").....	4
1.1.4 Agir rationnellement (" <i>Acting rationally</i> ").....	5
1.2 Les vagues de l'intelligence artificielle	7
1.2.1 La vague de l'IA prédictive	7
1.2.2 La vague de l'IA générative	7
1.2.3 La vague de l'IA agentique	8
Les grands domaines de l'intelligence artificielle	9
2.1 Machine learning.....	9
2.1.1 Apprentissage supervisé.....	10
2.1.2 Apprentissage non supervisé	14
2.1.4 Apprentissage par renforcement.....	15
2.1.5 Applications	16
2.2 Deep learning	17
2.2.1 Réseaux feedforward.....	18
2.2.2 Graphes computationnels	19
2.2.3 Réseaux convolutionnels	20
2.2.4 Algorithmes d'apprentissage	21
2.2.5 Généralisation	21
2.2.6 Réseaux récurrents	21
2.2.7 Apprentissage non supervisé	22
2.2.8 Deep Reinforcement Learning	22
2.2.9 Limites et critiques.....	23
2.3 Le Traitement Automatique du Langage Naturel (NLP).....	25
2.4 Logique et Raisonnement.....	26
2.5 Recherche opérationnelle et résolution algorithmique	26

2.6 Planification et ordonnancement	26
2.7 Vision par ordinateur	27
2.8 Agents physiques	27
Deep learning et les autres domaines	27
3.1 La vision par ordinateur (<i>computer vision</i>)	27
3.2 Traitement automatique du langage naturel	28
3.3 Neuro-Symbolic AI	29
3.4 Système Multi-agents	29
Au-delà du deep learning	30
4.1 Planification et agents	30
4.2 Modèles du monde	30
4.3 Modèles de raisonnement	31
Conclusion	32
Bibliographie	33

Introduction

Durant ces dernières décennies, progressivement, l'intelligence artificielle s'est fixé une place de choix dans le jeu des intérêts mondiaux. Les récentes avancées dans le domaine ont bousculé notre façon de voir et de comprendre le monde. Passant d'une maison dont les appareils sont contrôlés avec un simple smartphone à une ville tout entière qui enrichit l'expérience collective à l'aide de systèmes autonomes intelligents, aujourd'hui, on peut dire sans se tromper que l'IA touche à tout. Et dans cette grande famille, un membre se démarque particulièrement : l'apprentissage profond. Ce dernier est victime de ses succès, et ce dans de nombreux secteurs. Ses succès spectaculaires en vision, en traitement du langage ou encore en robotique ont contribué à renforcer l'idée que le deep learning représenterait, à lui seul, l'avenir de l'IA. Néanmoins, cette perception ne rend pas justice à la richesse d'un domaine qui englobe le raisonnement, la planification, l'apprentissage et bien plus encore. Face à cette situation, il est impératif de comprendre les rôles respectifs des différentes composantes en question.

C'est dans cette perspective que s'inscrit notre travail. Nous visons à analyser et comprendre ce qu'est l'intelligence artificielle, les possibilités qu'elle apporte, mais aussi la position des différents éléments de cet ensemble, spécialement l'apprentissage profond. Ainsi, notre problématique gravite autour de cette question : *Pourquoi étudier l'intelligence artificielle et pas uniquement l'apprentissage profond ?*

Pour y répondre, nous allons dans ce dossier présenter d'abord ce que le monde scientifique et professionnel entend par intelligence artificielle, examiner les principales branches qui la composent, avant d'analyser la manière dont le deep learning s'intègre à ces différentes approches.

Intérêt de la recherche

L'intérêt principal de cette recherche réside dans la volonté de mieux comprendre cette vaste famille qu'est l'intelligence artificielle et la place d'un membre prédominant qu'est l'apprentissage profond. Bien que ce dernier ait été au centre de nombreuses avancées, on est en droit de questionner sa place dans l'ensemble et de mesurer son importance de façon isolée. Cette étude aura pour but de mieux situer les différentes branches de l'intelligence artificielle.

Un autre intérêt est que, étant étudiant en data science, il est primordial d'avoir une vue globale et de pouvoir se positionner sur ces questions au vu de l'importance croissante que prend l'intelligence artificielle aujourd'hui.

Méthodologie

Dans le but de répondre à notre problématique de recherche, nous avons adopté une démarche qui englobe l'intelligence artificielle en général. Ceci a été fait de façon volontaire pour ne pas se limiter à l'apprentissage profond. Notre base théorique principale repose sur *Artificial Intelligence – A Modern Approach* de Stuart Russell et Peter Norvig, ouvrage qui reste une référence puisqu'il présente de manière structurée l'ensemble des approches de l'IA : symbolique, probabiliste, multi-agents, robotique, planification, et bien sûr apprentissage profond. Un choix qui semble pertinent car ces auteurs replacent le deep learning dans un cadre conceptuel beaucoup plus vaste.

À partir de ce point, nous avons constitué un corpus complémentaire d'articles scientifiques couvrant différentes branches de l'IA. Nous avons choisi ces articles en fonction de leur caractère récent, de leur position sur le deep learning et les autres branches de l'IA (raisonnement symbolique, planification automatique, systèmes multi-agents, robotique, NLP, etc.) et du raisonnement qu'ils en font. En conséquence, on s'assure une diversité assez large pour mieux explorer notre sujet.

Notre démarche s'est organisée en trois étapes. Dans un premier temps, nous avons défini l'intelligence artificielle à partir des différentes positions du monde scientifique et professionnel. Dans un second temps, nous avons présenté les principales branches avec un accent sur l'apprentissage automatique et profond. Pour ces branches, on a exploré les avantages et les domaines d'application. Et pour finir, nous avons analysé comment l'apprentissage profond interagit avec ces autres approches, mais aussi évoqué quelques-unes de ses limites lorsqu'il est considéré seul.

Cette méthodologie nous permet ainsi d'aborder l'intelligence artificielle dans sa globalité, de justifier pourquoi il est nécessaire d'étudier l'ensemble de ses branches, et de mieux comprendre la place réelle du deep learning dans cette grande famille

L'intelligence artificielle

Selon Stuart Russell et Peter Norvig, (Russell & Norvig, 2021) , on distingue aujourd'hui quatre grandes manières d'aborder la notion d'intelligence artificielle et les progrès réalisés dans ce domaine.

1.1 Approches de l'intelligence artificielle

1.1.1 Agir comme un humain ("*Acting humanly*")

L'idée centrale est de concevoir un système informatique capable de produire des réponses impossibles à différencier de celles d'un être humain. Ce principe renvoie au célèbre test de Turing. Décrit par Alan Turing, (Turing, 1950), dans *Computing Machinery and Intelligence*, ce test met en scène un évaluateur humain dialoguant à l'aveugle avec une machine et autre humain. Si l'évaluateur ne parvient pas à identifier qui est la machine, alors celle-ci réussit l'épreuve.

Pour atteindre un tel niveau de performance, quatre grands types de compétences sont nécessaires, mobilisant six disciplines :

- *Natural language processing*, pour comprendre et générer du langage humain ;
- *Knowledge representation*, pour organiser et conserver l'information ;
- *Automated reasoning*, pour inférer des réponses et tirer des conclusions ;
- *Machine learning*, pour apprendre et généraliser.

Dans une version plus complète du test, intégrant une interaction totale avec le monde réel, il faudrait ajouter :

- *Computer vision et speech recognition*, pour percevoir l'environnement ;
- *Robotics*, pour manipuler et se déplacer dans l'espace.

1.1.2 Penser comme un humain ("*Thinking humanly*")

Marvin Minsky, figure emblématique de l'IA aux côtés de John McCarthy et Douglas Engelbart, défendait l'idée qu'il est possible de reproduire les mécanismes cognitifs humains au moyen de machines agents. Cette vision repose sur la modélisation de l'architecture cognitive humaine.

Dans (Minsky, *Society of Mind*, 1988), il explique que l'intelligence humaine émerge de la collaboration d'une multitude d'agents spécialisés, chacun dédié à une fonction mentale (raisonnement, mémoire, etc.). Selon lui, reproduire ces interactions permettrait de générer des capacités cognitives complexes.

Il résume ainsi la discipline :

"Artificial intelligence is the science of making machines do things that would require intelligence if done by men" (Minsky, *Steps toward artificial intelligence in proceedings of the IRE*, 1961)

1.1.3 Penser rationnellement ("*Thinking rationally*")

John McCarthy, à qui l'on doit le terme même "intelligence artificielle", l'a introduit en 1955 lors de la préparation d'un atelier au Dartmouth College, qui deviendra le *Dartmouth Summer Research Project on Artificial Intelligence* en 1956 — une date souvent considérée comme fondatrice pour la discipline.

À la différence de Minsky, McCarthy s'est intéressé à une IA fondée sur la logique. À travers son langage LISP (*LIS*t *Pro*cessing), il a proposé de représenter la connaissance sous forme de symboles et de structures logiques. Encoder ces règles devait permettre à une machine de reproduire un raisonnement humain.

Il formulait ainsi cette idée :

" We shall therefore say that a program has common sense if it automatically deduces for itself a sufficiently wide class of immediate consequences of anything it is told and what it already knows" (McCarthy, 1959)

Couplé avec le framework proposé avant lui, *Logic Theorist*, développé en 1956 par Allen Newell et Herbert A. Simon, on posait les bases d'un système intelligent capable de fonctionner

par la manipulation de symboles et de règles logiques, jetant ainsi les fondations de l'IA symbolique.

Cette approche, premièrement soutenue par des auteurs comme Minsky et McCarthy, fait la représentation de systèmes qui cherchent à raisonner de manière comparable à l'être humain en utilisant des représentations structurées comme des faits, des concepts ou des relations. Les recherches ont évolué jusqu'à aujourd'hui, bien que quelque peu délaissée pendant un certain temps, on observe un regain d'intérêt pour l'IA symbolique en raison de ses possibilités, combinées à d'autres méthodes modernes. (Sabry, 2023), par exemple, met en avant les différents principes : les systèmes experts¹, les règles de production, les ontologies² ou encore les moteurs d'inférence qui permettent de déduire de nouvelles informations à partir d'un ensemble de connaissances formalisées. En se basant sur cette approche, on peut construire des systèmes interprétables où les étapes du raisonnement peut être explicitée et vérifiée.

Ce n'est pas sans raison que, dans la littérature francophone, l'IA symbolique est souvent décrite comme l'approche « classique » de l'intelligence artificielle. Les ouvrages tels qu' *"Apprentissage symbolique – Une approche de l'intelligence artificielle"* (Kodratoff, Michalski, & Jaime Guillermo Carbonell, 1993) décrivent comment la logique, la manipulation de symboles et les méthodes de recherche ont permis de développer des systèmes capables de résoudre des problèmes complexes se basant sur l'expérience. L'apprentissage symbolique repose sur la construction explicite de connaissances : les systèmes apprennent en fonction des règles et des symboles plutôt que de paramètres.

Globalement, l'IA symbolique représente un élément important de l'histoire de la conception de l'intelligence artificielle. Malgré quelques contraintes dans la gestion des données non structurées complexes, son aptitude à fournir des modèles compréhensibles et maîtrisables justifie son regain d'intérêt récent, en particulier dans les démarches hybrides qui tentent de fusionner ses atouts avec l'apprentissage profond.

1.1.4 Agir rationnellement ("Acting rationally ")

Russell et Norvig définissent un agent comme une entité qui agit. Même si tout programme informatique « fait » quelque chose, les agents sont attendus sur des critères supplémentaires :

¹ système d'IA conçu pour résoudre des problèmes de domaine spécifique

² concept, relation et règles dans un domaine de connaissances

autonomie, perception de leur environnement, persistance dans le temps, capacité d'adaptation et poursuite d'objectifs.

Un agent rationnel est celui qui choisit l'action conduisant au meilleur résultat possible ou, en situation d'incertitude, au meilleur résultat espéré (Russell & Norvig, 2021).

Cette approche met donc l'accent sur les agents rationnels. Aux débuts de l'IA, ces agents reposaient sur des structures logiques rigides et des plans déterministes. L'introduction de la théorie des probabilités puis de l'apprentissage automatique a ensuite permis de concevoir des agents capables de raisonner et d'agir de manière optimale même dans des environnements incertains

Ainsi, selon le type d'environnement (déterministe, stochastique, observable, etc.), on conçoit plusieurs types d'agents :

- **Les agents réflexes simples** : ils fonctionnent mieux dans un environnement totalement observable et reposent sur des règles simples qui permettent une catégorie limitée d'actions ;
- **Les agents réflexes basés sur un modèle interne** : ils possèdent une mémoire et permettent une meilleure représentation du monde ;
- **Les agents orientés objectifs** : à un niveau supérieur, ils choisissent leurs actions en fonction des buts à atteindre et s'appuient sur des mécanismes de recherche ou de planification ;
- **Les agents basés sur l'utilité** : ils peuvent redéfinir leurs objectifs en fonction de l'utilité, ce qui permet de gérer l'incertitude et des arbitrages complexes ;
- **Les agents apprenants** : ils s'adaptent de manière autonome en fonction de leur performance au fil de l'expérience acquise.

Le monde professionnel, "le métier", aurait quant à lui tendance à proposer une définition de l'IA basée sur la temporalité, avec une approche par vagues :

1.2 Les vagues de l'intelligence artificielle

1.2.1 La vague de l'IA prédictive

Le courant moteur de cette vague repose sur l'utilisation de modèles qui exploitent différents paramètres pour identifier des tendances, anticiper les comportements et faire des prédictions. L'apprentissage automatique (*machine learning*) est au cœur de cette approche avec ses capacités prédictives. Cette vague repose sur le traitement de données massives, où le modèle est d'abord entraîné sur un sous-ensemble des données (jeu d'entraînement), puis testé sur un jeu de test avant d'être déployé. Les applications sont variées, allant de la logistique et de la médecine, jusqu'aux campagnes marketing.

1.2.2 La vague de l'IA générative

L'IA générative, quant à elle, repose sur des techniques d'apprentissage profond plus avancées. Le programme est capable de produire du texte, des images, ou d'autres contenus en réponse aux requêtes d'un utilisateur. L'apprentissage repose sur des ensembles de données encore plus massifs et sur l'utilisation de modèles comme les grands modèles de langage (*Large Language Models*³, LLM). Ces modèles sont entraînés sur des millions de données en entrée, puis stockés dans des bases de données vectorielles (*vector databases*) qui permettent au modèle d'apprendre en fonction de la similarité entre les contenus. La notion d'*embedding* devient centrale, car elle permet une représentation numérique des éléments de données sous forme de vecteurs dans un espace multidimensionnel, facilitant ainsi le rapprochement entre les contenus similaires.

Une fois le modèle entraîné et affiné (*fine-tuning*⁴), il peut produire des résultats de haute qualité et continuer à interagir avec des sources externes grâce au RAG (*Retrieval-Augmented Generation*),⁵ ce qui permet d'améliorer encore ses performances. Ces modèles sont capables de générer en sortie des textes, des images, de la musique, etc. (ex. : *foundation models*⁶)

³ désigne les modèles d'IA générative capables de traiter le langage et de produire du texte, que ce soit en langues humaines ou en langages de programmation. Ils sont utilisés pour des tâches telles que la génération de texte, la traduction automatique, et bien d'autres applications.

⁴ Le fine-tuning est l'opération où un modèle IA déjà pré-entraîné sur de larges volumes de données est ré-entraîné sur un jeu de données plus spécifique afin de répondre à un besoin particulier, comme l'analyse de ventes.

⁵ une approche où le modèle apprend à partir de données spécialisées qu'il n'a pas apprises directement lors de son entraînement initial, en utilisant une base de données externe pour affiner ses connaissances.

⁶ des modèles qui peuvent être utilisés pour une large variété de types de données (texte, image, son, vidéo)

1.2.3 La vague de l'IA agentique

L'IA agentique se rapproche de la notion d'agent soulevée par Russell et Norvig. Il s'agit de programmes autonomes dotés de mémoire, capables d'exécuter des tâches complexes. Les agents construits sur la base des LLM peuvent, par eux-mêmes, apprendre à partir de sources externes, de leurs expériences passées, et ajuster leurs actions en conséquence.

On distingue ainsi plusieurs types d'agents :


1. **Les agents de fond (background agents)** : Ce sont des agents qui fonctionnent en dehors des interactions directes avec un utilisateur, et qui aident à gérer les processus internes d'un système.
2. **Les agents de surface (surface agents)** : Ce sont des agents qui interagissent directement avec l'utilisateur, comme les assistants virtuels (Siri, Alexa) ou les chatbots conversationnels.

Que ce soit le raisonnement logique, la recherche heuristique, la planification, la vision par ordinateur, le traitement du langage, le machine learning ou le deep learning, il s'agit d'utiliser un système capable d'exécuter des actions appropriées en fonction des besoins présents. On retrouve ainsi des agents qui s'appuient sur des règles logiques pour prendre des décisions, alors qu'un autre améliore sa performance en utilisant des modèles de machine learning ou de deep learning.

De ce fait, cette notion d'agent et cette volonté de créer des systèmes plus performants nous permet d'expliquer les interconnexions existantes entre les différents sous-domaines de l'IA.

Les grands domaines de l'intelligence artificielle

Figure 2-1 Les grands domaines de l'intelligence artificielle




Source: (Inventiv IT)

2.1 Machine learning

Le machine learning est un sous-domaine de l'intelligence artificielle qui regroupe un ensemble de méthodes capables d'apprendre à partir d'observations (*features*) et de réaliser des prévisions sur une donnée cible (*target*). Suivant la présence d'étiquettes (*label*) ou non, on distingue diverses approches pour des problèmes de régression (prédiction d'une variable continue) ou de classification (prédiction d'une variable discrète).


Figure 2-3 Régression et classification



Source : (Sarker, 2021)

L'ouvrage, "*The Elements of Statistical Learning*" (Friedman, Hastie, & Tibshirani, 2008), explore deux des quatre approches reconnues : l'apprentissage supervisé et non supervisé

Figure 2-2 Les approches en apprentissage automatique



Source : (Sarker, 2021)

2.1.1 Apprentissage supervisé

Méthodes linéaires et régularisées

Les modèles linéaires constituent la pierre angulaire de l'apprentissage statistique. Leur principe repose sur l'idée qu'une variable à expliquer peut-être représentée comme une combinaison de plusieurs variables explicatives en entrée. Malgré leur simplicité, ces modèles restent extrêmement efficaces dans de nombreux contextes, notamment lorsque les relations

entre variables sont approximativement linéaires ou lorsque la dimension des données est faible. Ils sont également valorisés pour leur interprétabilité. La variable cible est expliquée par l'effet partiel des variables explicatives, toute chose étant égale par ailleurs.

Toutefois, lorsque le nombre de variables augmente ou qu'il y a redondance d'information, fortes corrélations, les modèles linéaires classiques perdent en stabilité. D'où l'importance de la régularisation, qui impose une contrainte sur les coefficients du modèle afin de limiter les phénomènes de surapprentissage (le modèle reproduit trop fidèlement les données et ne peut plus être généralisé).


Par exemple, la Ridge Regression applique une pénalisation L2 qui réduit la magnitude des coefficients, tandis que le Lasso utilise une pénalisation L1 conduisant à la mise à zéro automatique de certains paramètres, ce qui permet de réaliser une sélection de variables intégrée au modèle. L'Elastic Net, une approche intermédiaire, est particulièrement adapté aux situations où plusieurs variables introduisent la même information.

Splines, lissage et modèles additifs

On tombe dans le cadre de modèles qui sont moins restrictifs que la contrainte de linéarité sans pour autant tomber dans des modèles totalement libres. Les *splines* séparent l'espace en différents segments et appliquent sur chacun une fonction polynomiale locale. Les modèles additifs généralisés (*Generalized Additive Model*, GAM) permettent de modéliser la variable cible comme la somme de fonctions lissées associées à chaque variable. Cette décomposition conserve une bonne interprétabilité car on peut toujours estimer l'effet partiel de chaque variable, ce qui constitue un avantage majeur dans des contextes appliqués comme l'épidémiologie, l'économie ou la modélisation environnementale. Avec des techniques de lissage comme les splines lissées ou les noyaux, les GAM constituent une alternative intermédiaire entre les modèles paramétriques et les approches non paramétriques.

Arbres de décision, bagging, random forests et boosting

Figure 2-4 Représentation Random Forest



Source : (Sarker, 2021)

Les arbres de décision permettent une décomposition binaire de l'espace de façon récursive en fonction de critères comme l'entropie, l'indice de Gini, etc. Néanmoins, un arbre isolé est souvent instable : une petite variation des données peut modifier profondément sa structure. Pour pallier cette faiblesse, les méthodes ensemblistes ont été introduites. Le bagging consiste à entraîner une multitude d'arbres sur différents jeux d'apprentissage puis à agréger leurs prédictions. Cela réduit considérablement la variance du modèle final. Le modèle de Random Forest se base sur ce principe.

Le boosting, quant à lui, utilise une stratégie séquentielle : chaque nouveau modèle apprend à corriger les erreurs commises par les modèles précédents. Contrairement au bagging, le boosting, par sa méthode de correction d'erreur (gradient), construit une structure progressive qui le rend très performant. Ces techniques sont aujourd'hui très efficaces pour les données tabulaires.

Méthodes de voisinage

Les méthodes de voisinage reposent sur l'hypothèse que des observations proches dans l'espace partagent les mêmes caractéristiques. L'algorithme k plus proches voisins (*k-Nearest*

Neighbors) illustre cette logique : pour prédire une valeur ou une classe, il suffit d'appliquer un principe de vote majoritaire sur les observations les plus proches.

Cette approche est très flexible car elle ne repose sur aucune hypothèse paramétrique forte. Cependant, elle souffre fortement de la malédiction de la dimension : lorsque le nombre de variables augmente, les distances perdent leur sens et tous les points tendent à devenir également éloignés.

Les méthodes basées sur des fonctions noyau (kernel smoothing, Nadaraya-Watson, etc.) atténuent partiellement ce problème en pondérant les voisinages selon une fonction de proximité.

Machines à Vecteurs de Support (SVM)

Les SVM cherchent à trouver la meilleure frontière possible (hyperplan) qui divise les classes de données. Le principe est de maximiser la marge, c'est-à-dire la distance entre les données de chaque classe et l'hyperplan décisionnel.

À l'aide des noyaux, les SVM projettent implicitement les données dans des espaces de grande dimension où les classes deviennent linéairement séparables. Les noyaux les plus courants sont les noyaux gaussiens (*Radial Basis Function*, RBF), polynomiaux et sigmoïdes. Cette capacité à gérer la non-linéarité en se basant sur un cadre théorique solide a fait des SVM un standard dans les années 2000 pour la reconnaissance d'images, de texte et la bioinformatique.

Toutefois, plus le volume des données augmente, plus le coût associé est conséquent, ce qui a réduit leur usage dans les applications massives où les réseaux neuronaux se sont imposés.

Réduction de dimension

La réduction de dimension permet de simplifier les données tout en préservant au maximum l'information. L'Analyse en Composantes Principales (ACP) est l'une des techniques les plus reconnues : elle transforme les variables initiales en composantes principales qui maximisent l'inertie (information) projetée sur des axes factoriels.

Utile pour la visualisation, dans le contexte de variantes non linéaires telles que l'ACP à noyau, elle permet de révéler des structures courbes dans des jeux de données complexes. La réduction de dimension joue un rôle central dans les pipelines d'apprentissage modernisés, notamment en prétraitement.

Bootstrap, validation croisée et contrôle biais/variance

L'ouvrage met également en lumière des outils d'évaluation de la stabilité des modèles. Le bootstrap permet d'estimer la variabilité d'un modèle en répétant son entraînement sur différents échantillons. La validation croisée, quant à elle, divise les données en plusieurs partitions, entraîne de façon itérative le modèle sur un sous-ensemble et teste sur les autres sous-ensembles.

Ces techniques sont intimement liées au compromis entre biais (erreur due à une simplification excessive du modèle) et variance (sensibilité excessive aux données d'entraînement). Une bonne méthode d'apprentissage statistique cherche un compromis(*trade-off*) pour atteindre la meilleure généralisation possible.

2.1.2 Apprentissage non supervisé

Les méthodes non supervisées s'intéressent à l'organisation interne des données sans variable cible. Le clustering est l'approche la plus connue, avec des méthodes comme *K-means*, le clustering hiérarchique ou DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*). Ces techniques cherchent à regrouper des observations similaires, soit en fonction d'un centre de groupes, soit en fonction de la densité des données (détection anomalie, segmentation).

Les modèles de mélange, en particulier les mélanges gaussiens, quant à elles adoptent une approche probabiliste qui permet de représenter des structures plus complexes

2.1.3 Apprentissage semi-supervisé

Selon (Chapelle, Schölkopf, & Zien, 2006), cette approche repose sur l'idée que la fonction réelle qui relie les entrées aux sorties peut être approximée par un modèle paramétrique ou non paramétrique, tant que l'on dispose d'un nombre suffisant d'exemples représentatifs. L'objectif central demeure de réduire au maximum l'erreur de prédiction lorsqu'on se trouve face à de nouvelles données. Dans cette optique, l'apprentissage supervisé peut être compris comme un véritable problème d'optimisation soumis à des contraintes statistiques : le modèle doit s'adapter aux observations disponibles tout en reflétant, autant que possible, l'organisation réelle de la distribution dont elles sont issues.

Les auteurs rappellent que les approches supervisées classiques partent du principe que les variables explicatives fournissent suffisamment d'information pour établir une frontière de décision pertinente. La régularisation, quant à elle, sert de garde-fou : elle empêche le modèle de coller trop étroitement aux données d'entraînement et donc de perdre en capacité de généralisation.

Le principe se base sur une combinaison d'un petit ensemble de données annotées et d'un grand nombre de données non annotées pour entraîner un modèle plus performant que celui obtenu uniquement avec des données étiquetées. On entraîne d'abord un modèle standard de l'approche supervisée, puis on formule des hypothèses sur les données non étiquetées en fonction de leur proximité ou de leur distance dans l'espace des données.

Le processus commence donc par l'entraînement du modèle sur les données annotées. Ensuite, les données non annotées sont exploitées en s'appuyant sur des hypothèses telles que la proximité entre points similaires ou la structure en clusters. On distingue ainsi plusieurs modèles, comme le pseudo-étiquetage, la *consistency regularization* ou encore les modèles génératifs, qui permettent de réduire le besoin en données annotées tout en améliorant les performances du modèle.

2.1.4 Apprentissage par renforcement

L'apprentissage par renforcement (*Reinforcement Learning*, RL) est un cadre dans lequel un agent apprend à interagir avec un environnement afin de maximiser une récompense cumulative. Sutton et Barto, (Sutton & Barto, 2018), définissent le RL comme un processus d'apprentissage fondé sur l'essai-erreur : l'agent, sans « enseignant », apprend en fonction de son expérience. Contrairement à l'apprentissage supervisé, le RL utilise uniquement un signal de récompense, qui peut être rare, retardé ou bruité. Cela rend cette approche particulièrement adaptée aux problèmes de décision séquentielle, où chaque action a des conséquences futures.

Le processus de décision markovien (*Markov Decision Process*, MDP) est au cœur des fondements mathématiques qui définissent l'interaction entre l'agent et son environnement. Sutton et Barto distinguent deux éléments essentiels : la politique, qui décrit le comportement de l'agent, et les fonctions de valeur, qui estiment la qualité des états ou des actions en termes de récompense attendue à long terme. L'apprentissage de ces valeurs repose sur des méthodes telles que la programmation dynamique, l'apprentissage temporel (*Temporal Difference*

learning) et les méthodes Monte-Carlo, qui diffèrent par la façon dont elles exploitent les retours d'expérience pour ajuster les estimations de valeur.

Les auteurs rappellent que le RL n'est pas seulement une technique d'optimisation, mais un cadre général permettant de comprendre comment un agent autonome raisonne et interagit dans un environnement incertain.

2.1.5 Applications

Cet éventail de méthodes trouve ses applications dans différents secteurs (Sarker, 2021).

Dans le domaine de l'analyse prédictive, les modèles apprennent des relations entre les variables afin de faire des prédictions. Leur utilisation est utile pour la détection de fraude, la logistique et la segmentation client.

La cybersécurité représente un autre champ d'application majeur. Des experts utilisent l'apprentissage automatique pour identifier des malwares ou encore améliorer la protection du cloud. Notamment grâce à l'utilisation d'agents capables de surveiller, défendre et isoler avec d'autres agents.

Dans le domaine de l'Internet des objets (*Internet of Things*⁷, IoT) et des villes intelligentes, l'apprentissage automatique favorise l'automatisation des environnements interconnectés, la prédiction de phénomènes urbains (comme le trafic, la consommation d'énergie, la disponibilité de ressources) et la mise en place de services intelligents en réponse aux besoins de la communauté.

L'optimisation mise en place pour améliorer l'expérience utilisateur profite également aux systèmes de transport. Grâce aux modèles prédictifs, il est possible de minimiser les congestions routières, de réduire les émissions polluantes ou d'optimiser les déplacements.

Dans le domaine médical, et spécifiquement en lien avec la pandémie de COVID-19, les méthodes d'apprentissage se sont révélées bénéfiques pour l'identification en amont des patients à risque et la projection de la progression de l'épidémie.

Le commerce en ligne et le commerce de détail utilisent ces technologies pour créer des systèmes de recommandation capables d'ajuster l'offre en fonction des préférences

⁷ réseau d'objets physiques connectés à Internet capables de collecter, transmettre et échanger des données

individuelles, d'optimiser la gestion des stocks ou encore d'améliorer l'efficacité logistique grâce à l'analyse des habitudes d'achat.

Dans le cadre de l'agriculture durable, ces techniques sont présentes sur toute la chaîne de valeur : anticipation des rendements, gestion de l'irrigation, détection des maladies des cultures, planification de la production ou analyse des préférences des consommateurs.

Au-delà de ces secteurs, le machine learning est d'une assistance importante dans d'autres domaines comme la bioinformatique, la finance, les réseaux, la robotique ou l'ingénierie.

2.2 Deep learning

L'apprentissage profond (*deep learning*) constitue aujourd'hui une famille majeure de méthodes d'intelligence artificielle. Elle se base sur des hypothèses de circuits algébriques complexes composés d'unités interconnectées. D'où le nom de modèles « profonds » parce que ces circuits sont organisés en plusieurs couches successives, de sorte que les chemins de calcul reliant les entrées aux sorties comportent de nombreuses transformations intermédiaires. Ce qui permet aux réseaux neuronaux de modéliser des relations non linéaires très complexes qu'il serait difficile, voire impossible, de capturer avec des algorithmes plus simples comme la régression linéaire ou logistique.

Ces modèles ont leurs racines théoriques dans les travaux pionniers de McCulloch et Pitts (1943), qui ont établi le premier neurone artificiel sous la forme d'une porte logique qui allait par la suite devenir les réseaux de neurones artificiels. Les réseaux neuronaux, contrairement aux méthodes de modélisation traditionnelles, sont particulièrement aptes à traiter les données de haute dimension comme les images, les signaux sonores ou les textes. Ils sont efficaces grâce à leur capacité à apprendre automatiquement des représentations hiérarchiques, surpassant largement les performances de modèles strictement linéaires. Bien que ces derniers restent très pratiques en vue de leur interprétabilité, la méthode de prédiction qui consiste à ajouter un poids aux différents coefficients et en faire un calcul limite leur puissance face à la modélisation des phénomènes courants souvent plus complexe.

Dans un réseau neuronal, chaque unité calcule une combinaison pondérée des signaux entrants, puis applique une fonction d'activation non linéaire. Cette opération peut être exprimée par :

$$a_j = g_j(\sum_i w_{i,j} a_i) \equiv g_j(in_j) \quad (2,1)$$

où a_j est la sortie du neurone j , $w_{i,j}$ le poids de la connexion entre les unités i et j , et g_j une fonction d'activation :

- Sigmoide ou logistique

$$\sigma(x) = \frac{1}{1+e^{-x}} \quad (2,2)$$

- ReLU, unité linéaire rectifiée (*rectified linear unit*)

$$ReLU(x) = \max(0, x) \quad (2,3)$$

- Softplus , une version lisse du ReLU


$$softplus(x) = \log(1 + e^x) \quad (2,4)$$

Cette fonction d'activation ajoute de la non-linéarité : elle permet, selon le théorème de l'approximation universelle, à un réseau d'approximer toute fonction continue, même lorsque l'architecture reste relativement simple.

2.2.1 Réseaux feedforward

Les réseaux feedforward constituent la forme la plus simple et la plus fondamentale de réseau neuronal. Leur structure va dans une seule direction : le modèle prend en entrée les informations (inputs) qui circulent vers les sorties sans jamais revenir en arrière, ce qui correspond à un graphe orienté acyclique (*DAG, directed acyclic graph*).

Figure 2-6 Régression vs Deep learning



Source: (Russell & Norvig, 2021)

(a) Un modèle peu profond, comme la régression linéaire, possède des chemins de calcul courts entre les entrées et la sortie.

(b) Un réseau de liste de décisions comporte certains chemins longs pour certaines valeurs d'entrée possibles, mais la plupart des chemins sont courts.


(c) Un réseau d'apprentissage profond présente des chemins de calcul plus longs, ce qui permet à chaque variable d'interagir avec toutes les autres.

On retrouve également dans cette catégorie les perceptrons multicouches (*Multi-Layer Perceptron, MLP*), qui sont largement utilisés pour des objectifs de classification ou de régression. Chaque couche apprend une transformation de l'espace d'entrée qui permet une construction progressive de représentations plus complexes (low dimension to high dimension). Les réseaux convolutionnels (*Convolutional Neural Network, CNN*), très utilisés en vision artificielle, peuvent également être vus comme une forme spécialisée de réseau feedforward pour détecter des motifs locaux (de petites structures ou caractéristiques spécifiques).

2.2.2 Graphes computationnels

En ce qui concerne le fonctionnement des architectures profondes, Russell et Norvig insistent sur le rôle des graphes computationnels, un schéma dans lequel chaque opération (multiplication matricielle, fonction d'activation, normalisation, etc.) constitue un nœud, et les flux de données de l'entrée à la sortie forment les connexions du graphe.

Figure 2-7 RNN vs feedforward




Source : (Russell & Norvig, 2021)

a) Schéma d'un RNN de base où la couche cachée possède des connexions récurrentes ; le symbole Δ indique un retard. (b) Le même réseau déroulé sur trois pas de temps pour former un réseau feedforward.

Ainsi, l'entraînement du modèle ressemble à une succession d'opérations différentiables qui peut être ajustée grâce à la correction d'erreur par gradient (backpropagation). Les frameworks actuels comme TensorFlow ou PyTorch, qu'on peut utiliser avec le logiciel Python, reposent précisément sur ce processus d'abstraction⁸ permettant l'optimisation efficace d'architectures très profondes sur GPU(*Graphics Processing Units*) /TPU(Tensor Processing Units)⁹.

2.2.3 Réseaux convolutionnels

Figure 2-8 Représentation CNN



Source : (Sarker, 2021)

Les réseaux convolutionnels (CNN) représentent une avancée majeure en vision artificielle. Ils utilisent des filtres locaux partagés qui opèrent comme des détecteurs de motifs. La convolution confère deux propriétés essentielles :

- la réduction drastique du nombre de paramètres grâce au partage de poids ;
- une invariance aux translations des motifs dans l'image.

Les couches de convolution se combinent à des opérations de pooling permettant ainsi une diminution de la résolution, mais conservent néanmoins l'information importante. Les CNN apprennent donc des représentations hiérarchiques : contours → textures → formes → objets.

⁸ capacité pour un modèle à apprendre de représentations de plus en plus complexes

⁹ processeurs spécialisés

Ce principe, inspiré du cortex visuel biologique, a conduit à des modèles performants comme LeNet, AlexNet, VGG, ResNet ou EfficientNet.

2.2.4 Algorithmes d'apprentissage

En apprentissage profond, l'entraînement repose sur des méthodes d'optimisation visant à minimiser une fonction de perte. La descente de gradient stochastique (*Stochastic Gradient Descent*, SGD) constitue la base du processus, mais des variantes plus avancées ont été développées pour améliorer la convergence, telles qu'Adam, RMSProp ou Momentum. Ces méthodes adaptent le taux d'apprentissage en fonction du gradient, ce qui permet d'optimiser l'entraînement.

La régularisation joue également un rôle central pour éviter le surapprentissage :

- Le dropout désactive aléatoirement des neurones pendant l'entraînement.
- La normalisation de lot (batch normalization) stabilise la distribution des activations.
- L'early stopping (arrêt précoce) prévient la dégradation des performances sur de nouvelles données.

Ces techniques sont indispensables pour entraîner des modèles profonds à grande échelle.

2.2.5 Généralisation

Bien que les réseaux profonds disposent de suffisamment de paramètres pour mémoriser les données, ils ne peuvent pas échapper au phénomène de surapprentissage. Russell et Norvig soulignent que la capacité des réseaux à généraliser repose sur des biais inductifs implicites liés à la structure même des architectures, à la régularisation et à la dynamique de l'optimisation. Cependant, la compréhension théorique de la généralisation en deep learning reste un domaine ouvert, avec de nombreux défis, tels que la complexité des fonctions de perte ou des minima locaux rencontrés.

2.2.6 Réseaux récurrents

À la différence des réseaux feedforward, les réseaux récurrents (RNN) permettent des connexions rétroactives, induisant ainsi des cycles dans le graphe computationnel. Ces cycles permettent à l'information de persister dans des états internes, et rendent le processus capable

de mémoriser les événements passés. Un RNN reçoit donc non seulement l'entrée courante, mais aussi l'état précédent. Ce mécanisme est crucial pour traiter des données séquentielles telles que le texte, l'audio ou les séries temporelles.

Cependant, les RNN classiques souffrent de gradients explosifs ou évanescents¹⁰. Pour surmonter ces limitations, des architectures spécialisées ont été développées :

- LSTM (*Long Short-Term Memory*), qui dispose de portes contrôlant l'entrée, la sortie et l'oubli de l'information.
- GRU (*Gated Recurrent Unit*), qui est plus simple mais presque aussi efficace que les LSTM.

Ces modèles ont dominé le traitement du langage naturel (NLP) jusqu'à l'émergence des *Transformers*¹¹, qui remplacent la récursivité par un mécanisme d'attention.

2.2.7 Apprentissage non supervisé

L'apprentissage supervisé n'est pas la seule approche utilisée dans le deep learning. Les modèles non supervisés, tels que les autoencodeurs, sont formés pour compresser puis reconstruire les données, ce qui leur donne la capacité de tirer des représentations latentes significatives. Des modèles alternatifs, tels que les GAN ou les autoencodeurs variationnels, apprennent des distributions génératives capables de créer de nouveaux exemples crédibles. Les techniques de transfert d'apprentissage sont aussi d'une grande importance : un réseau déjà formé sur une vaste quantité de données (par exemple, ImageNet) peut être ajusté pour une nouvelle tâche nécessitant peu d'étiquettes, diminuant ainsi le besoin en annotation manuelle.

2.2.8 Deep Reinforcement Learning

Stuart Russell et Peter Norvig présentent le deep reinforcement learning en tant qu'évolution moderne et performante du renforcement traditionnel, où l'apprentissage en profondeur est utilisé pour estimer des fonctions de valeur, de politique ou de modèle dans des environnements trop étendus ou continus pour les techniques tabulaires classiques. Ils mettent en avant que

¹⁰ les premières couches apprennent très lentement ou n'apprennent plus du tout, ce qui empêche l'apprentissage des motifs complexes.

¹¹ un modèle qui transforme une séquence en une autre (texte, code, images, audio...) en utilisant une suite de blocs d'encodeur et/ou de décodeur, en grande partie grâce au fait que ces blocs se "regardent" les uns les autres (self-attention)

l'incorporation de réseaux neuronaux permet aux agents d'apprendre directement à partir de données brutes — images, états complexes, signaux sensoriels — ce qui rend réalisable l'acquisition de comportements complexes comme ceux observés dans Atari ou AlphaGo. Toutefois, ils soulignent également les problèmes majeurs liés au deep RL : l'instabilité de l'apprentissage, le coût élevé de l'échantillonnage, la sensibilité aux hyperparamètres, l'absence de garanties théoriques et la complexité de la généralisation. Le RL est une percée remarquable encore en développement, qui nécessite des efforts considérables pour renforcer sa solidité, sa fiabilité et sa sûreté, particulièrement dans les systèmes autonomes concrets.

2.2.9 Limites et critiques

En dépit de ses apports majeurs et de ses vastes champs d'application, le deep learning n'est pas sans limites.

Limite en reconnaissance d'objets

D'un côté, dans certains domaines comme la médecine, il est difficile d'étiqueter certaines données (résultats de scanners, radiographies, etc.). L'étiquetage de ces données nécessite l'intervention d'experts, ce qui rend le processus coûteux. De plus, l'apprentissage profond demande des quantités importantes de données d'entraînement.

D'un autre côté, l'entraînement d'un modèle entraîne des coûts énergétiques élevés, sans parler de la complexité des architectures qui rend leur déploiement difficile sans matériel adapté.

En outre, ce type de modèle reste susceptible aux attaques. On distingue généralement les catégories suivantes :

- a) Attaque d'évasion (*adversarial example*) : une petite perturbation appliquée à une image suffit pour que le modèle prévoie une autre classe souhaitée (par exemple transformer la prédiction d'un ours polaire en ours brun).
- b) Attaque physique : perturbations réelles (autocollants, motifs imprimés, peinture, lunettes adversariales, vêtements) qui faussent les analyses du modèle dans le monde réel.
- c) Attaque par empoisonnement (*poisoning /backdoor*) : injection d'exemples trafiqués dans le jeu d'entraînement afin de manipuler le comportement du modèle.
- d) Attaque de confidentialité : attaques visant à exposer des informations sensibles sur les données d'entraînement (inférence de présence d'un individu dans le dataset, reconstruction, etc.).

Coûts

Dans leurs études, "*The Computational Limits of Deep Learning*", (Thompson, Greenewald, Lee, & Manso, 2020), Thompson et ses collaborateurs proposent une analyse systématique du rôle central joué par la puissance de calcul dans les progrès récents du deep learning. Ce travail, basé sur un large corpus d'articles couvrant plusieurs domaines de l'IA tels que la vision, la traduction et le traitement du langage, montre que les avancées obtenues dépendent fortement de l'augmentation simultanée de trois facteurs : la taille des modèles, la quantité de données d'entraînement et la capacité de calcul mobilisée. Leur conclusion met en lumière une caractéristique fondamentale du problème actuel : les gains de performance ne proviennent pas principalement d'innovations conceptuelles, mais plutôt d'un accroissement massif des ressources matérielles engagées. Cette dynamique crée une dépendance à une croissance exponentielle du calcul, laquelle devient rapidement difficile à soutenir.

Selon Thompson, les limites économiques et écologiques rendent les modèles les plus avancés uniquement accessibles aux grandes organisations capables d'investir dans des infrastructures de calcul colossales. De ce fait, sans prendre en compte la viabilité écologique, l'innovation et la recherche scientifique, au niveau du deep learning moderne, sont limitées par manque de ressources et ne peuvent pas être ainsi généralisées à l'ensemble de la communauté.

Enfin, Thompson et al. insistent que si cette dépendance au calcul persiste, le deep learning pourrait atteindre un plafond en termes de progrès imposé non pas par des limites mathématiques, mais par des contraintes matérielles et économiques.

Leur analyse ouvre ainsi la voie à une réflexion sur des directions alternatives pour l'IA comme l'utilisation de méthodes hybrides, modèles exploitant des connaissances externes ou l'utilisation de techniques plus efficiente d'apprentissage automatique

Dans cette perspective, suivant les recherches récentes, (Canatar, Bordelon, & Pehlevan, 2021) sur les réseaux de neurones très larges montrent que la capacité d'un modèle à généraliser ne dépend non seulement de sa taille, mais aussi de la manière dont il est structuralement adapté à

la tâche. Ce principe est mis en avant par des concepts comme *Neural Tangent Kernel*¹²(NTK), le (*spectral bias*)¹³ et l'alignement tâche-modèle¹⁴ (*task-model alignment*),

Ces résultats suggèrent que l'on peut concevoir des systèmes plus intelligents et efficaces, capables d'apprendre avec moins de paramètres et moins de calculs, en exploitant la structure des données et les caractéristiques spécifiques des tâches. En conséquence, un modèle plus petit, mieux adapté à la tâche, suffit aux modèles plus larges.

2.3 Le Traitement Automatique du Langage Naturel (NLP)

Il s'agit d'une branche de l'intelligence artificielle et de l'informatique qui a pour but de doter les machines de la capacité à comprendre, produire et manipuler le langage humain (écrit et oral), en fusionnant la linguistique, les modèles statistiques et l'apprentissage profond. Cette discipline couvre une multitude de tâches, allant de la tokenisation et du marquage morphosyntaxique à la reconnaissance des entités, l'analyse des sentiments, la traduction automatique et la création de contenu textuel.

En pratique, les solutions industrielles actuelles utilisent des pipelines hybrides combinant des règles / linguistique computationnelle pour certaines phases et des modèles statistiques et neuronaux (comme les *word embeddings*, *transformers* ou LLMs) pour l'extraction de représentations et la génération. Cela rend possible des applications telles que les assistants virtuels, la recherche sémantique, l'analyse documentaire et l'automatisation des flux de travail. Aujourd'hui, parmi les modèles les plus connus on retrouve : GPT-4, GPT-4.1 et GPT-5 (OpenAI), LLaMA 2 et LLaMA 3 (Meta), Claude 3 – Haiku, Sonnet, Opus (Anthropic), Gemini – Nano, Pro, Ultra (Google), ainsi que Mistral 7B, Mixtral 8x7B et Mixtral 8x22B (Mistral AI).

Toutefois il y a des défis persistants : besoins massifs en données, biais et inégalité entre langues à haute ressource¹⁵ et langues peu-ressources à côté des enjeux de protection de données, de transparence et de conformité (RGPD)

¹² Un réseau très large en apprentissage se comporte comme une régression à noyau (prédiction en se basant d'exemples connus) classique, plutôt que d'apprendre de nouvelles caractéristiques complexes.

¹³ Les réseaux apprennent progressivement : d'abord les motifs faciles à capturer, puis les motifs plus complexes.

¹⁴ Si le modèle est bien "aligné" avec la tâche, il apprend plus facilement et généralise mieux, même avec moins de paramètres.

¹⁵ langue pour laquelle il existe beaucoup de données et beaucoup d'outils permettant d'entraîner et de tester des modèles

2.4 Logique et Raisonnement

Le Raisonnement et la Représentation des Connaissances (*Knowledge Representation*, KRR) portent sur l'organisation des connaissances sous des formes symboliques structurées, telles que des faits, des relations, des règles, des ontologies ou des graphes de connaissances, afin de permettre aux systèmes informatiques de raisonner et d'inférer tout en suivant un ensemble de règles dans leurs décisions.

Les méthodes couramment utilisées comprennent les logiques formelles, les ontologies, les moteurs d'inférence, les graphes sémantiques, les systèmes experts et la représentation déclarative. Par exemple, l'architecture cognitive symbolique *Soar* modélise la cognition et la résolution de problèmes à travers des états, des opérateurs et des résultats. Les principales applications incluent le diagnostic dans les domaines médical et industriel, les systèmes de support à la prise de décision, la planification, la simulation ainsi que la compréhension des règles métier

2.5 Recherche opérationnelle et résolution algorithmique

Ce champ d'étude porte un intérêt particulier aux algorithmes qui investiguent ou améliorent un espace de solutions, généralement sans apprentissage ou avec un apprentissage réduit. Cela englobe des méthodes comme la recherche par arbre, A*, les problèmes de satisfaction de contraintes (*Constraint Satisfaction Problems*, CSP), l'optimisation linéaire et non linéaire, les algorithmes génétiques ainsi que les heuristiques. Les domaines d'application sont nombreux : la logistique, la planification industrielle, l'allocation de ressources, le scheduling, la gestion des réseaux et la résolution de problèmes combinatoires.

2.6 Planification et ordonnancement

L'objectif de la planification automatique est de créer des séries d'actions conçues pour atteindre un but spécifique, en tenant compte des restrictions associées à la situation mondiale, aux ressources disponibles ou au facteur temps. Les méthodes courantes comprennent les planificateurs symboliques, la recherche d'états, la planification hiérarchique, conditionnelle ou temporelle, et l'incorporation dans des systèmes à plusieurs agents. Les applications incluent la robotique autonome, la gestion logistique, l'automatisation industrielle, la coordination multi-agents et les workflows automatisés.

2.7 Vision par ordinateur

L'objectif de la vision par ordinateur est d'équiper les machines de la capacité à appréhender le monde visuel, en analysant des images ou des vidéos afin d'en déduire des données interprétables : objets, formes, déplacements, scènes ou structures en 3D. Parmi les méthodes employées, on trouve la détection et l'identification d'objets, la segmentation, le suivi par vidéo, l'évaluation de mouvement, la reconstruction en 3D ainsi que la vision stéréoscopique. Il existe de nombreuses applications : identification de visages, détection d'anomalies, imagerie médicale, voitures autonomes, robotique, contrôle, inspection industrielle et réalité augmentée. L'importance de la vision par ordinateur réside dans sa capacité à permettre aux systèmes d'appréhender et d'interpréter le monde réel, ce qui est indispensable pour des domaines tels que la robotique, l'analyse d'images et la prise de décisions autonomes.

2.8 Agents physiques

La robotique fusionne l'intelligence artificielle, la mécanique, l'électronique et le contrôle afin de concevoir des machines aptes à percevoir, décider, intervenir et s'ajuster dans la réalité. Les éléments clés comprennent la perception (vision et senseurs), la planification et le contrôle, le processus décisionnel, la modélisation de l'environnement, la navigation, la manipulation et l'interaction entre l'homme et le robot. Les applications couvrent un large éventail, allant des robots industriels et de service aux drones, en passant par les véhicules autonomes, les robots médicaux, l'exploration, la logistique et l'aide humaine

Deep learning et les autres domaines

Dans les lignes qui ont précédé, on a relevé les caractéristiques des différents domaines de l'IA. L'accent a surtout été mis sur l'apprentissage automatique et l'apprentissage profond. Mais comme mentionné implicitement et explicitement, ces domaines sont interconnectés. Dans cette section, on relève les connexions qui existent entre le deep learning et d'autres branches de l'intelligence artificielle.

3.1 La vision par ordinateur (*computer vision*)

Nous débutons avec la vision par ordinateur, un domaine qui a probablement bénéficié le plus de l'essor de l'apprentissage profond, et qui a également contribué à stimuler ses avancées. En 1989, LeCun et ses collaborateurs ont exploité un réseau de neurones convolutif pour reconnaître les chiffres manuscrits sur le courrier postal. Il a fallu attendre 2012 pour que l'architecture AlexNet, développée par Alex Krizhevsky, Ilya Sutskever et Geoffrey Hinton,

remporte le concours ImageNet dédié à la reconnaissance d'images, marquant ainsi un regain d'intérêt pour ce domaine.

Depuis lors, la vision par ordinateur a connu des avancées majeures grâce à de nombreuses recherches, ouvrant la voie à des applications variées, notamment en médecine et dans d'autres secteurs :

- détection du cancer de la peau (Andre, et al., 2017) ;
- diagnostic à partir de radiographies thoraciques (Rajpurkar, et al., 2017) ;
- détection de maladies à partir de divers types de scanners (Geert, 2017) ;
- colorisation automatique de photos en noir et blanc (Zhang, Isola, & Efros, 2016) ;
- génération d'images haute résolution à partir d'entrées de faible résolution (Dong, Loy, He, & Tang, 2013) ;
- estimation de pose en temps réel (Jain, Tompson, Lecun, & al., 2014) ;
- génération automatique de légendes pour des images et vidéos (K & al, 2015).

3.2 Traitement automatique du langage naturel

Le *deep learning* a été un acteur majeur dans le traitement automatique du langage naturel, en offrant aux modèles la capacité d'acquérir automatiquement des représentations et des structures issues de divers textes, sans se fier exclusivement à des règles linguistiques. Selon (Collobert & Weston, 2008), il est possible d'entraîner des réseaux de neurones de manière *end-to-end* pour diverses tâches de traitement du langage naturel, en reproduisant les performances obtenues sur de multiples tâches. Cette approche a largement amélioré les résultats dans des domaines tels que l'identification d'entités nommées, la catégorisation de texte et la prédiction de segments de discours, en tirant parti du contexte global et des liens sémantiques entre les termes.

Le *deep learning*, en utilisant des structures telles que les réseaux de neurones convolutifs pour détecter des motifs et les réseaux récurrents pour modéliser les dépendances séquentielles, a révolutionné le traitement du langage naturel (NLP) en proposant des modèles plus adaptables, robustes et capables de généraliser sur de grandes quantités de données textuelles. Cette évolution a préparé le terrain pour les modèles linguistiques contemporains, qui continuent de progresser vers des performances de plus en plus proches de la compréhension humaine.

3.3 Neuro-Symbolic AI

En dépit des différents atouts dont jouissent les réseaux de neurones, ils restent confrontés aux limites que l'on a énumérées : opacité des décisions, résultats contraires aux contraintes du domaine, etc.

C'est pourquoi il est nécessaire de les combiner avec des approches symboliques, notamment la logique, les ontologies ou les systèmes de raisonnement structuré. Cette approche hybride permet d'imposer explicitement des règles métier et de mettre en place une structure qui garantit l'explicabilité et la vérifiabilité des décisions.

L'approche SAIF-DL (*Symbolic-AI-Fusion Deep Learning*), (Machot, Horsch, & Ullah, 2024) l'a démontré de façon opérationnelle : en intégrant des règles logiques (via la programmation par ensembles d'ensembles — ASP) directement dans la fonction de perte d'un réseau neuronal, de façon à contraindre l'apprentissage à respecter les contraintes du domaine, ce qui améliore la robustesse, la précision et la cohérence des sorties.

De son côté, dans une étude sur le KRR (*Knowledge Representation and Reasoning*), (Lee, 2024) montre, de manière théorique, que les deux approches n'ont aucun bénéfice à opérer seules : l'une pour le raisonnement, l'autre pour la reconnaissance de motifs complexes. Ensemble, elles offrent le meilleur des deux mondes, ouvrant la voie à une IA plus fiable et adaptative, particulièrement adaptée aux environnements critiques (comme la cybersécurité, la santé ou les systèmes intelligents).

3.4 Système Multi-agents

(Nguyen, Nguyen, & Nahavandi, 2018) soulignent comment l'apprentissage profond révolutionne les systèmes multi-agents en leur permettant une meilleure représentation d'environnements complexes. L'usage des réseaux neuronaux permet à chaque agent de gérer des observations partielles, des états continus ainsi que des scènes visuelles ou dynamiques qu'il serait impossible de modéliser en utilisant des techniques traditionnelles. Ainsi, les agents ne se limitent plus à la simple application de règles : ils apprennent de manière proactive à agir, réagir et s'ajuster les uns aux autres, générant ainsi des comportements collectifs complexes.

En fin de compte, le deep learning remplit une double fonction : il aide les agents à appréhender des environnements complexes et à élaborer des politiques performantes, tout en transformant ces agents en la structure qui gère la collaboration, la coordination ou la rivalité. Les applications telles que la coordination de drones, la robotique collaborative ou encore la gestion

d'énergie distribuée démontrent que l'association entre les agents et le deep learning est extrêmement prometteuse, même si beaucoup de défis demeurent à relever.

Au-delà du deep learning

À côté de la multitude de possibilités qu'apporte le deep learning aux autres techniques de l'IA, nombreux sont les recherches et les applications qui voient le jour et vont au-delà de ces applications.

4.1 Planification et agents

Des chercheurs de l'université de Pékin, (Zhou, et al.), ont proposé l'utilisation de nouveaux agents de planification utilisant les LLM pour une planification à long terme. Ils reposeraient sur les principes de planification – vérification – exécution – réflexion (métacognition), plutôt que le schéma, plus simple planification → exécution → réflexion, utilisé dans de nombreux agents contemporains. Cet agent, le Metagent-P, permet de créer des plans basés sur l'expérience, de vérifier leur cohérence à l'aide de règles structurées, puis d'adapter ses actions face à des situations imprévues.

Grâce à cette combinaison mémoire + raisonnement symbolique + contrôle métacognitif, Metagent-P est beaucoup plus performant en termes de robustesse et d'efficacité que les agents utilisant seulement les LLM. Celui-ci excelle particulièrement sur les tâches longues avec des capacités supérieures aux capacités cognitives humaines. Ce modèle illustre bien l'intérêt des approches hybrides pour aller au-delà des limites du deep learning seul et avancer vers des agents vraiment adaptatifs dans des environnements complexes.

4.2 Modèles du monde

Rohit Bandaru, Machine Learning Software Engineer chez Google, (Bandaru, 2025), explique dans son blog personnel, la notion de modèle du monde (*world model*). Ce sont des agents intelligents qui, munis d'une représentation interne, sont censés être capables de prédire un environnement en constante évolution et d'intégrer ces informations dans leurs actions.

Contrairement aux IA traditionnelles, basées sur des expériences passées, les world models permettent d'anticiper, de raisonner sur les conséquences et de planifier, à la manière des humains qui imaginent mentalement des scénarios avant d'agir. Ces capacités constituent un pas majeur pour le développement d'agents autonomes.

4.3 Modèles de raisonnement

Les modèles de fondation vont au-delà du deep learning traditionnel en s'appuyant sur d'énormes corpus diversifiés, ce qui leur permet d'élaborer des représentations globales du monde plutôt que de se cantonner à une tâche spécifique. Cette abondance d'entraînement fait émerger des capacités telles que le raisonnement, la planification ou l'adaptation à des circonstances nouvelles, sans qu'elles soient explicitement codées. Si l'on ajoute à ces modèles des modules logiques ou s'ils sont intégrés dans des agents, ils deviennent capables d'analyser des problèmes complexes et d'ajuster leurs actions selon le contexte. Ils ne se limitent donc plus à de simples modèles statistiques, mais deviennent de véritables modèles de raisonnement, symbolisant le développement d'une IA plus complète et mieux équipée pour gérer des problèmes du quotidien.

En définitive, l'apprentissage profond a transformé plusieurs domaines de l'intelligence artificielle, mais il est évident qu'il n'est qu'un élément d'un écosystème plus vaste. Les approches hybrides, qui fusionnent le raisonnement symbolique, les modèles de type world models, la métacognition et les modèles de raisonnement, démontrent que l'intelligence artificielle est capable de dépasser une simple approche statistique.

L'intelligence artificielle est beaucoup plus, c'est celle qui intègre la perception, la mémoire, la planification et la réflexion.

Conclusion

Ce dossier de veille a le mérite de survoler l'ensemble des méthodes de l'intelligence artificielle. Une place majeure a été accordée au rôle de l'apprentissage profond. Nous avons pu constater que, malgré le succès de ce dernier, à lui seul il ne suffit pas face aux demandes qui attendent d'être comblées et en raison de ses propres limitations. En examinant les autres branches — raisonnement symbolique, planification, systèmes multi-agents, robotique, représentation des connaissances, etc. — nous avons pu remarquer que ces éléments ne sont pas mutuellement disjoints, mais qu'ils démontrent leur pleine potentialité lorsqu'ils sont utilisés en commun. Ainsi, nous avons pu mettre en évidence la complémentarité qui existe avec l'apprentissage profond.

Cette approche globale révèle que l'IA contemporaine progresse surtout lorsque ces différentes méthodes sont exploitées de manière cohérente et que l'une parvient à compenser les faiblesses de l'autre. Dans ce cadre, les systèmes hybrides, qui combinent approche par apprentissage et raisonnement, apparaissent comme les agents du futur, mieux dotés pour résoudre des problèmes plus complexes.

En définitive, comprendre la place du deep learning dans l'ensemble des approches de l'IA ne revient pas à minimiser son importance, mais à reconnaître que l'intelligence artificielle est un domaine beaucoup plus vaste et en constante évolution. C'est justement cette diversité qui permet d'aborder des problèmes toujours plus complexes et de concevoir des systèmes intelligents plus fiables, plus adaptatifs et plus complets.

Bibliographie

- Andre, E., Brett, K., A., N. R., Justin, K., M., S. S., M., B. H., & Sebastien, T. (2017). Dermatologist level classification of skin cancer with deep neural networks. *Nature*, 115-118.
- Bandaru, R. (2025, Mars 02). Consulté le Décembre 8, 2025, sur <https://rohitbandaru.github.io/blog/World-Models/>
- Canatar, A., Bordelon, B., & Pehlevan, C. (2021). Spectral bias and task-model alignment explain generalization in kernel regression and infinitely wide neural networks. *Harvard Brain Science Initiative*.
- Chapelle, O., Schölkopf, B., & Zien, A. (2006). *Semi-Supervised Learning*. MIT Press.
- Collobert, R., & Weston, J. (2008). A unified architecture for natural language processing: Deep neural networks with multitask learning. *Proceedings of the 25th international conference on Machine learning.*, 160-167.
- Dong, C., Loy, C. C., He, K., & Tang, X. (2013). Image Super-Resolution Using Deep Convolutional Networks. *IEEE*, 8599-8603.
- Friedman, J., Hastie, T., & Tibshirani, R. (2008). *The Elements of Statistical Learning, Data Mining, Inference and Prediction*. Springer.
- Geert, L. (2017). A survey on deep learning in medical image analysis. *Med Image Anal*, 60–88.
- Ian Goodfellow, Y. B., & Courville, A. (2016). *Deep Learning*. The MIT Press.
- Inventiv IT. (s.d.). Les grands domaines de l'intelligence artificielle. France. Consulté le Novembre 30, 2025, sur <https://inventiv-it.fr/intelligence-artificielle/>
- Jain, A., Tompson, J., Lecun, Y., & al., e. (2014). "Modeep: A deep learning framework using motion features for human pose estimation.". *Springer International Publishing*.
- K, X., & al, e. (2015). Show, attend and tell: neural image caption generation with visual attention. *Journal of Physics: Conference Series*, 2048–2057.
- Kodratoff, Y., Michalski, R. S., & Jaime Guillermo Carbonell, J. (1993). *Apprentissage symbolique : une approche de l'intelligence artificielle*. Toulouse: Cépaduès.
- Lee, A. (2024). Knowledge Representation and Reasoning in AI: Analyzing Different Approaches to Knowledge Representation and Reasoning in Artificial Intelligence Systems. *Journal of artificial intelligence research*.
- Machot, F. A., Horsch, M. T., & Ullah, H. (2024). Symbolic-AI-Fusion Deep Learning (SAIF-DL): Encoding Knowledge into Training with Answer Set Programming Loss Penalties by a Novel Loss Function Approach.
- McCarthy, J. (1959). Programs with Common Sense. *Institute of Radio Engineers*.
- Minsky, M. (1961). *Steps toward artificial intelligence in proceedings of the IRE*. Institute of Radio Engineers.
- Minsky, M. (1988). *Society of Mind*. Simon & Schuster.

- Nguyen, T. T., Nguyen, N. D., & Nahavandi, S. (2018). Deep Reinforcement Learning for Multi-Agent Systems: A Review of Challenges, Solutions and Applications. *IEEE Transactions on Cybernetics*.
- Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., . . . Ng, A. Y. (2017). Radiologist-level pneumonia detection on chest x-rays with deep learning. *arXiv preprint arXiv*.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A modern Approach*. Pearson Series.
- Sabry, F. (2023). *Symbolic Artificial Intelligence*. One Billion Knowledgeable.
- Sarker, I. H. (2021). Machine Learning: Algorithms, Real-World Applications and Research Directions. *SN Comput Sci*.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning An Introduction*. MIT Press.
- Thompson, N. C., Greenewald, K., Lee, K., & Manso, G. F. (2020). The computational limits of deep learning . *MIT initiative on the digital economy research brief*.
- Turing, A. (1950). Computing Machinery and Intelligence. 443-4460.
- Zhang, R., Isola, P., & Efros, A. A. (2016). Colorful image colorization. In European conference on computer vision. *Springer International Publishing.*, 649-666.
- Zhou, Y., Liu¹, Y., Li, X., Zhao, Y., Wang, X., Tian, J., . . . Xu, X. (s.d.). Metagent-P: A Neuro-Symbolic Planning Agent with Metacognition for Open Worlds. *Alibaba International Digital Commerce*, 22 747 -22 755.